

# Clasificación de Sexismo en tweets

MIARFID - ALC - Laboratorio 1

Shiyi Cheng - Pablo Segovia Martínez

26 de febrero de 2026

## 1. Introducción

Este proyecto aborda la tarea de detección automática de contenido sexista en publicaciones de redes sociales, utilizando el dataset de la competición EXIST 2025. El objetivo es desarrollar y evaluar diferentes aproximaciones de clasificación binaria (sexista/no sexista) mediante modelos clásicos de machine learning y modelos de lenguaje pre-entrenados con fine-tuning.

## 2. Metodología

### 2.1. Preprocesamiento de Datos

Se han implementado dos estrategias de preprocesamiento:

- **Tweet Original:** Texto sin modificaciones, manteniendo URLs, menciones y emojis.
- **Text Clean:** Limpieza avanzada eliminando URLs, menciones, hashtags, y normalizando el texto.

### 2.2. Modelos Evaluados

Se ha experimentado con tres familias de modelos:

#### 2.2.1. Modelos Clásicos

Modelos de machine learning tradicionales utilizando vectorización TF-IDF y Bag-of-Words:

- Regresión Logística
- Support Vector Machines (LinearSVC, SVC-RBF)
- Árboles de Decisión y Random Forest
- Gradient Boosting y AdaBoost
- Naive Bayes (Multinomial, Complement, Bernoulli)
- K-Nearest Neighbors
- Ensamblados (Voting, Bagging, Stacking)

### 2.2.2. Modelos de Lenguaje Fine-tuned

Modelos transformer pre-entrenados ajustados con LoRA (Low-Rank Adaptation):

- **F2LLM-4B**: Modelo de 4B parámetros especializado en español
- **KaLM**: Modelo multilingüe con soporte para español

### 2.2.3. Modelos Generativos

Modelos grandes de lenguaje evaluados en modo zero-shot e inference con fine-tuning:

- **Ministral-3-8B-Instruct**: Modelo instruccional de 8B parámetros con cuantización FP8

## 3. Resultados

### 3.1. Métricas en Conjunto de Validación (DEV)

La Tabla 1 muestra los resultados de los modelos de lenguaje fine-tuned, mientras que la Tabla 2 presenta los mejores modelos clásicos.

Modelo	Accuracy	Precision	Recall	F1-Score
F2LLM-4B (tweet)	<b>0.8604</b>	0.8294	0.8642	<b>0.8464</b>
Ministral-3-8B (FT)	0.8451	<b>0.8587</b>	0.7802	0.8176
KaLM (tweet)	0.8429	0.8164	0.8346	0.8254
F2LLM-4B (clean)	0.8341	0.7581	<b>0.9210</b>	0.8317
KaLM (clean)	0.8363	0.8137	0.8198	0.8167
Ministral-3-8B (ZS)	0.8264	0.7892	0.8321	0.8101

Tabla 1: Resultados de Modelos de Lenguaje (DEV)

Modelo	Accuracy	Precision	Recall	F1-Score
Stacking	<b>0.7824</b>	0.7867	0.7012	<b>0.7415</b>
Gradient Boosting	0.7736	<b>0.8373</b>	0.6099	0.7057
LinearSVC	0.7736	0.7901	0.6691	0.7246
Logistic Regression	0.7725	0.7845	0.6741	0.7251
Bagging (LR)	0.7703	0.7849	0.6667	0.7210

Tabla 2: Mejores Modelos Clásicos (DEV) - TF-IDF

### 3.2. Análisis Comparativo

#### 3.2.1. Rendimiento por Familia de Modelos

- **Modelos de Lenguaje**: Los modelos transformer fine-tuned superan significativamente a los modelos clásicos, con mejoras de hasta **+10.5 puntos** en F1-Score (F2LLM-4B vs Stacking). El fine-tuning de Ministral-3-8B mejora todas las métricas respecto a su versión zero-shot, alcanzando la mayor precision (0.8587) de todos los modelos evaluados.

- **Modelos Clásicos:** El ensamble mediante Stacking alcanza el mejor rendimiento ( $F1=0.7415$ ), demostrando que la combinación de múltiples clasificadores mejora los resultados individuales.
- **Impacto del Preprocesamiento:**
  - Los textos originales (tweet) obtienen mejor *accuracy* y *precision*
  - Los textos limpios (clean) mejoran el *recall* en +5.7 puntos (F2LLM-4B)
  - El trade-off entre precision y recall depende de la estrategia de preprocesamiento

### 3.2.2. Mejores Configuraciones

1. **Mayor F1-Score:** F2LLM-4B con tweet original (0.8464)
2. **Mayor Recall:** F2LLM-4B con texto limpio (0.9210)
3. **Mayor Precision:** Ministral-3-8B fine-tuned (0.8587)
4. **Mejor modelo clásico:** Stacking con TF-IDF (0.7415)

## 4. Conclusiones

1. Los modelos de lenguaje pre-entrenados con fine-tuning superan ampliamente a los métodos clásicos de ML, especialmente en tareas de comprensión contextual como la detección de sexismo.
2. El modelo F2LLM-4B con texto original alcanza el mejor equilibrio entre precision y recall (**F1=0.8464**), constituyendo la mejor solución para esta tarea.
3. La estrategia de preprocesamiento debe seleccionarse según el objetivo: texto limpio maximiza recall (detectar más casos positivos), mientras que el texto original mejora precision (evitar falsos positivos).
4. Los ensambles de modelos clásicos (Stacking) son competitivos y computacionalmente más eficientes que los LLMs, representando una alternativa válida para entornos con recursos limitados.
5. El fine-tuning con LoRA permite adaptar modelos grandes (4B-8B parámetros) con recursos limitados, manteniendo alta calidad en las predicciones.

### 4.1. Trabajo Futuro

- Explorar ensambles de modelos de lenguaje (votación entre F2LLM, KaLM y Ministral)
- Análisis de errores para identificar patrones lingüísticos desafiantes
- Optimización de hiperparámetros mediante búsqueda sistemática
- Evaluar arquitecturas más recientes y técnicas de prompting avanzadas